

NYC Yellow Taxi

Big Data & Machine Learning Pipeline

Kullanılan Teknolojiler

Apache Kafka • Apache Spark • Delta Lake • MLflow • Python • Docker

Bilge Çeşme — 220201045
Merve Özdemir — 230201118
Mustafa Tiftik — 230201126

Ders: Büyük Veri Analizine Giriş
Tarih: 12.05.2026

1. Proje Özeti

Bu proje, NYC Yellow Taxi verisini kullanarak uçtan uca bir Big Data + Machine Learning akış hattı kurar.

Projenin temel amacı; veri üretiminden başlayıp Kafka ile gerçek zamanlı aktarım, Spark Structured Streaming ile Bronze katmanına yazma, EDA ve feature engineering ile Silver katmanını oluşturma, MLflow destekli model eğitimi ve en sonunda görselleştirme ile sonuçların raporlanmasını kapsayan bütünlük bir sistem ortaya koymaktır.

Veri Katmanları

- **Bronze Katman:** Ham, işlenmemiş streaming verisi — Delta Lake üzerinde kalıcı depolama
- **Silver Katman:** Temizlenmiş ve zenginleştirilmiş veri — modellemeye hazır
- **Gold Katman:** Model tahminleri ve analiz sonuçları — raporlama için hazır

2. Notebook Açıklamaları

Notebook	Amaç	Gerçekleştirilen Çalışmalar	Çıktı / Sonuç
Notebook 1 — Kafka Producer	Ham NYC Taxi verisini gerçek zamanlı veri akışına dönüştürmek	Parquet verisi okunarak Kafka topic'ine batch halinde gönderildi. Zaman damgası ve olay tabanlı meta alanlar üretildi.	Spark Streaming bileşeni için sürekli veri akışı sağlayan Kafka tabanlı veri kaynağı oluşturuldu.
Notebook 2 — Spark Structured Streaming	Kafka'dan gelen veriyi Delta Lake Bronze katmanına aktarmak	Spark Structured Streaming ile veri akışı işlendi, JSON parse işlemleri yapıldı ve append modunda Bronze katmanına yazıldı.	Sürekli güncellenen, güvenli ve kalıcı bir Bronze veri katmanı oluşturuldu.
Notebook 3 — Keşifsel Veri Analizi (EDA)	Veri kalitesini analiz etmek ve veri profilini çıkarmak	Eksik değer, hatalı kayıt, istatistiksel özet ve saatlik yoğunluk analizleri gerçekleştirildi.	Veri problemleri ve temizleme ihtiyaçları belirlenerek modelleme öncesi veri yapısı analiz edildi.
Notebook 4 — Feature Engineering	Veriyi modelleme için uygun hale getirmek	Veri filtreleme, zaman tabanlı özellik çıkarımı ve yeni değişken üretimi gerçekleştirildi.	Temizlenmiş ve zenginleştirilmiş Silver veri katmanı oluşturuldu.
Notebook 5 — Model Training & MLflow	Farklı regresyon modellerini eğitmek ve karşılaştırmak	Linear Regression, Decision Tree, Random Forest, GBT ve GLR modelleri eğitildi. MLflow ile deney takibi yapıldı.	En yüksek R ² skoruna sahip model seçildi ve Gold katmanına tahmin sonuçları yazıldı.
Notebook 6 — Visualization & Reporting	Analiz sonuçlarını görselleştirmek ve raporlamak	EDA grafikleri, model performans karşılaştırmaları ve MLflow deney sonuçları görselleştirildi.	Karar alıcılar ve teknik ekipler için yorumlanabilir bir raporlama katmanı oluşturuldu.

3. Ek Altyapı Bileşenleri

docker-compose.yml

- Tüm servisler Docker ortamında orkestrasyonu sağlanır
- Kafka, Spark, MLflow, Jupyter servisleri yönetilir
- Producer servisi de kapsama dahildir
- Servisler arası network yapılandırması yapılır

producer.py

- Notebook dışı üretim senaryosuna uygun tasarım
- Tekrar kullanılabilir Kafka producer uygulaması
- Bağımsız çalıştırılabilir script formatı
- CI/CD entegrasyonu için uygundur




Fig1: Model Eğitim sonuçları

```
Eğitiliyor: Linear_Regression...
Linear_Regression Sonuçları - RMSE: 12.8477, R2: 0.5413, MAE: 7.1967
🔗 View run Linear_Regression at: http://mlflow:5000/#/experiments/1/runs/e3e209ea22d6485ba3a7b3b22118208d
🌱 View experiment at: http://mlflow:5000/#/experiments/1

Eğitiliyor: Decision_Tree...
2026/05/11 08:49:53 WARNING mlflow.utils.environment: Encountered an unexpected error while inferring pip requirements (model URI: /tmp/tmpkm7onjh5/model, flavor: spark). Fall back to return ['pyspark==3.5.0']. Set logging level to DEBUG to see the full traceback.
Decision_Tree Sonuçları - RMSE: 7.0100, R2: 0.8634, MAE: 2.3860
🔗 View run Decision_Tree at: http://mlflow:5000/#/experiments/1/runs/1142af35360b4c40a1629b55c62b1b16
🌱 View experiment at: http://mlflow:5000/#/experiments/1

Eğitiliyor: Random_Forest...
Random_Forest Sonuçları - RMSE: 7.9353, R2: 0.8250, MAE: 2.7327
🔗 View run Random_Forest at: http://mlflow:5000/#/experiments/1/runs/eab24f2b02794e64b9900cf40aaadcb1
🌱 View experiment at: http://mlflow:5000/#/experiments/1

Eğitiliyor: GBT_Regressor...
GBT_Regressor Sonuçları - RMSE: 7.5069, R2: 0.8434, MAE: 2.0821
🔗 View run GBT_Regressor at: http://mlflow:5000/#/experiments/1/runs/49eb7abb271453d885f3e22ff8293ef
🌱 View experiment at: http://mlflow:5000/#/experiments/1

Eğitiliyor: GLR_Regressor...
GLR_Regressor Sonuçları - RMSE: 12.8477, R2: 0.5413, MAE: 7.1967
🔗 View run GLR_Regressor at: http://mlflow:5000/#/experiments/1/runs/c50fc12499334ce6aee8ec44505d2109
🌱 View experiment at: http://mlflow:5000/#/experiments/1

GOLD KATMANI OLUŞTURULUYOR...
Tahminler ve artık (residual) değerleri /app/delta/taxi_gold dizinine kaydedildi.

TÜM MODELLER EĞİTİLDİ VE MLFLOW'A KAYDEDİLDİ.
```

Fig2: Model Eğitim süreci



Fig3: Grafikler

4. Karşılaşılan Zorluklar

Proje sürecinde en büyük zorluklardan biri, Kafka üzerinden akan ham NYC Taxi verilerindeki aykırı ve tutarsız kayıtlar olmuştur. Negatif ücret değerleri, mantıksız yolculuk mesafeleri ve eksik veriler model performansını olumsuz etkilediğinden, veri temizleme ve filtreleme işlemleri kritik hale gelmiştir.

Bir diğer önemli problem ise büyük veri işleme sırasında yaşanan kaynak yetersizliğidir. Özellikle Spark, Kafka ve ML modellerinin Docker ortamında birlikte çalıştırılması sırasında RAM kullanımı ciddi şekilde artmış ve birçok kez “Out Of Memory (OOM)” hataları alınmıştır. Bu problemi azaltmak amacıyla batch boyutları küçültülmüş, işlenen veri miktarı sınırlandırılmış ve bellek kullanımı optimize edilmiştir.

5. Genel Sonuç ve Değerlendirme

Proje, veri mühendisliği, makine öğrenmesi ve DevOps pratiklerini bir araya getirerek üretimdeki bir Big Data sisteminin taslağını başarıyla ortaya koymuştur.

Bu proje, modern veri mühendisliği ve makine öğrenmesi uygulamalarının uçtan uca nasıl entegre edileceğini başarılı bir şekilde göstermektedir. Gerçek zamanlı veri akışından model eğitime kadar olan tüm aşamalar, sektör standardı araçlarla hayata geçirilmiştir.